

Chapitre1: Simulation de variables aléatoires

Monte Carlo

Mohsen CHEBBI

ESPRIT

February 13, 2026



Plan

- ① Méthode de Monte Carlo
 - Principe et démarche
 - Validation et comportement de la méthode

Plan

- 1 Méthode de Monte Carlo
 - Principe et démarche
 - Validation et comportement de la méthode
- 2 Méthodes de simulation
 - Méthode d'inversion
 - Méthode de Box Muller

Plan

- ① **Méthode de Monte Carlo**
 - Principe et démarche
 - Validation et comportement de la méthode
- ② **Méthodes de simulation**
 - Méthode d'inversion
 - Méthode de Box Muller
- ③ **Simulation de variables aléatoires**
 - Simulation des lois continues
 - Simulation des lois discrètes
 - Simulation de loi gaussienne

Plan

- 1 Méthode de Monte Carlo
 - Principe et démarche
 - Validation et comportement de la méthode
- 2 Méthodes de simulation
 - Méthode d'inversion
 - Méthode de Box Muller
- 3 Simulation de variables aléatoires
 - Simulation des lois continues
 - Simulation des lois discrètes
 - Simulation de loi gaussienne
- 4 Vérification de la simulation
 - Approche graphique
 - Test d'adéquation

Motivation

Une option asiatique est un produit dérivé dont la valeur dépend de la moyenne des prix d'un actif sous-jacent sur une période donnée. Contrairement à une option classique (européenne ou américaine), dont le prix est basé sur la valeur du sous-jacent à un instant précis (comme le prix d'expiration).

Motivation

Une option asiatique est un produit dérivé dont la valeur dépend de la moyenne des prix d'un actif sous-jacent sur une période donnée. Contrairement à une option classique (européenne ou américaine), dont le prix est basé sur la valeur du sous-jacent à un instant précis (comme le prix d'expiration).



Motivation

Une option asiatique est un produit dérivé dont la valeur dépend de la moyenne des prix d'un actif sous-jacent sur une période donnée. Contrairement à une option classique (européenne ou américaine), dont le prix est basé sur la valeur du sous-jacent à un instant précis (comme le prix d'expiration).



Question:

Comment calculer la prime de cette option?

Plan

Méthode de Monte Carlo

Définition et principe

Définition

La méthode de Monte Carlo est une méthode numérique fondée sur la simulation de variables aléatoire ou de trajectoires des processus stochastiques afin d'estimer des quantités numériques complexes (*espérances, probabilités*). Elle consiste à remplacer les calculs analytiques difficiles ou impossibles par des moyennes empiriques issues d'un grand nombre de simulations indépendantes.

Définition et principe

Définition

La méthode de Monte Carlo est une méthode numérique fondée sur la simulation de variables aléatoire ou de trajectoires des processus stochastiques afin d'estimer des quantités numériques complexes (*espérances, probabilités*). Elle consiste à remplacer les calculs analytiques difficiles ou impossibles par des moyennes empiriques issues d'un grand nombre de simulations indépendantes.

Exemples d'application

La simplicité, la flexibilité et l'efficacité de la méthode de Monte Carlo, notamment pour les problèmes en grande dimension, en font un outil largement utilisé dans les applications financières et réglementaires :

- Pricing d'options et produits dérivés : estimation de payoffs complexes.

Définition et principe

Définition

La méthode de Monte Carlo est une méthode numérique fondée sur la simulation de variables aléatoire ou de trajectoires des processus stochastiques afin d'estimer des quantités numériques complexes (*espérances, probabilités*). Elle consiste à remplacer les calculs analytiques difficiles ou impossibles par des moyennes empiriques issues d'un grand nombre de simulations indépendantes.

Exemples d'application

La simplicité, la flexibilité et l'efficacité de la méthode de Monte Carlo, notamment pour les problèmes en grande dimension, en font un outil largement utilisé dans les applications financières et réglementaires :

- Pricing d'options et produits dérivés : estimation de payoffs complexes.
- Gestion de portefeuille et risques : évaluation des distributions de pertes et mesures de risque (VaR, CVaR).

Définition et principe

Définition

La méthode de Monte Carlo est une méthode numérique fondée sur la simulation de variables aléatoire ou de trajectoires des processus stochastiques afin d'estimer des quantités numériques complexes (*espérances, probabilités*). Elle consiste à remplacer les calculs analytiques difficiles ou impossibles par des moyennes empiriques issues d'un grand nombre de simulations indépendantes.

Exemples d'application

La simplicité, la flexibilité et l'efficacité de la méthode de Monte Carlo, notamment pour les problèmes en grande dimension, en font un outil largement utilisé dans les applications financières et réglementaires :

- Pricing d'options et produits dérivés : estimation de payoffs complexes.
- Gestion de portefeuille et risques : évaluation des distributions de pertes et mesures de risque (VaR, CVaR).
- Solvabilité et stress tests réglementaires : simulation de scénarios économiques et financiers pour tester la résilience.

Principe

Supposons que l'on souhaite connaître la valeur d'une certaine quantité θ .

Principe

Supposons que l'on souhaite connaître la valeur d'une certaine quantité θ .

Principe

Le principe de la méthode de Monte Carlo consiste à écrire le problème sous la forme d'une espérance. Autrement dit:

$$\theta = \mathbb{E}[h(X)], \text{ avec } h : \mathbb{R} \rightarrow \mathbb{R} \text{ est une fonction mesurable}$$

Puis, estimer θ par la moyenne empirique:

$$\theta_n = \frac{1}{n} \sum_{k=1}^n h(X_k)$$

En simulant une suite de variables aléatoires $(X_n)_{n \geq 1}$ indépendantes et identiquement distribuées (i.i.d.) suivant la loi de X .

Démarche

Identifier la quantité à estimer, puis décrire le modèle stochastique ou la variable aléatoire qui gouverne le phénomène.

Démarche

Identifier la quantité à estimer, puis décrire le modèle stochastique ou la variable aléatoire qui gouverne le phénomène.

Générer un grand nombre de réalisations indépendantes de la variable ou du processus stochastique, puis calculer la quantité d'intérêt.

Démarche

Identifier la quantité à estimer, puis décrire le modèle stochastique ou la variable aléatoire qui gouverne le phénomène.

Générer un grand nombre de réalisations indépendantes de la variable ou du processus stochastique, puis calculer la quantité d'intérêt.

Calculer la moyenne des résultats simulés, qui fournit l'approximation de la quantité recherchée.

Démarche

Identifier la quantité à estimer, puis décrire le modèle stochastique ou la variable aléatoire qui gouverne le phénomène.

Générer un grand nombre de réalisations indépendantes de la variable ou du processus stochastique, puis calculer la quantité d'intérêt.

Calculer la moyenne des résultats simulés, qui fournit l'approximation de la quantité recherchée.

Améliorer les approximations trouvées en utilisant les techniques de réduction de la variance.

Questions se posent naturellement

Comment assurer/justifier cette approximation ?

Questions se posent naturellement

Comment assurer/justifier cette approximation ?

Comment évaluer cette approximation ?

Questions se posent naturellement

Comment assurer/justifier cette approximation ?

Comment évaluer cette approximation ?



Convergence de la méthode

La convergence de la méthode est assurée par la loi des grands nombres.

Convergence de la méthode

La convergence de la méthode est assurée par la loi des grands nombres.

Loi des Grands Nombres (LGN)

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de variables aléatoires réelles i.i.d ayant une **espérance** $m \in \mathbb{R}$ et une **variance** $\sigma^2 \in \mathbb{R}_+$, alors on a:

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow[n \rightarrow \infty]{p.s.} m$$

(Ceci implique donc la convergence en probabilité)

Vitesse de convergence et estimation de l'erreur Monte Carlo

La méthode de Monte Carlo présente une vitesse de convergence de l'ordre de $O\left(\frac{1}{\sqrt{n}}\right)$, où n représente la taille de l'échantillon. En conséquence, l'erreur diminue à un taux proportionnel à l'inverse de la racine carrée de la taille de l'échantillon.

Vitesse de convergence et estimation de l'erreur Monte Carlo

La méthode de Monte Carlo présente une vitesse de convergence de l'ordre de $O\left(\frac{1}{\sqrt{n}}\right)$, où n représente la taille de l'échantillon. En conséquence, l'erreur diminue à un taux proportionnel à l'inverse de la racine carrée de la taille de l'échantillon.

Théorème Central Limite (TCL)

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de v.a.r i.i.d ayant une espérance $m \in \mathbb{R}$ et une variance $\sigma^2 > 0$ alors, on a:

$$\frac{\sqrt{n}(\bar{X}_n - m)}{\sigma} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

Vitesse de convergence et estimation de l'erreur Monte Carlo

La méthode de Monte Carlo présente une vitesse de convergence de l'ordre de $O\left(\frac{1}{\sqrt{n}}\right)$, où n représente la taille de l'échantillon. En conséquence, l'erreur diminue à un taux proportionnel à l'inverse de la racine carrée de la taille de l'échantillon.

Théorème Central Limite (TCL)

Soit $(X_n)_{n \in \mathbb{N}}$ une suite de v.a.r i.i.d ayant une espérance $m \in \mathbb{R}$ et une variance $\sigma^2 > 0$ alors, on a:

$$\frac{\sqrt{n}(\bar{X}_n - m)}{\sigma} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1)$$

L'erreur commise par la méthode de Monte Carlo est aléatoire. Elle ne peut être précisée, mais elle peut être quantifiée via un intervalle de confiance.

Problématique

Comment faire pour la simulation des
v.a. $X_1, \dots, X_n$?

Problématique

Comment faire pour la simulation des
v.a. $X_1, \dots, X_n$?



Plan

Méthodes de simulation

Méthode d'inversion

Théorème: Théorème de représentation

Soit X une variable aléatoire à valeurs dans $\mathbb{R}^d$, alors il existe:

- Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}^d$ mesurable.
- Un vecteur de variables aléatoires $(U_1, U_2, \dots, U_n)$ indépendantes et uniformément réparties sur l'intervalle $[0, 1]^n$.

telque:

$$X = f(U_1, U_2, \dots, U_n) \quad (\text{en loi})$$

Méthode d'inversion

Théorème: Théorème de représentation

Soit X une variable aléatoire à valeurs dans $\mathbb{R}^d$, alors il existe:

- Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}^d$ mesurable.
- Un vecteur de variables aléatoires $(U_1, U_2, \dots, U_n)$ indépendantes et uniformément réparties sur l'intervalle $[0, 1]^n$.

telque:

$$X = f(U_1, U_2, \dots, U_n) \quad (\text{en loi})$$

La méthode d'inversion permet de simuler une variable aléatoire réelle selon une loi donnée, à partir d'un générateur uniforme, dès lors que l'on peut calculer l'inverse de sa fonction de répartition.

Fonction de répartition

Fonction de répartition d'une v.a. discrète

Soit X une v.a. discrète à valeurs dans $X(\Omega)$. La fonction de répartition de X notée F_X est définie sur $\mathbb{R}$ par:

$$F_X(x) = \sum_{y \in X(\Omega) | y \leq x} \mathbb{P}(X = y)$$

Fonction de répartition

Fonction de répartition d'une v.a. discrète

Soit X une v.a. discrète à valeurs dans $X(\Omega)$. La fonction de répartition de X notée F_X est définie sur $\mathbb{R}$ par:

$$F_X(x) = \sum_{y \in X(\Omega) | y \leq x} \mathbb{P}(X = y)$$

Fonction de répartition d'une v.a. continue

Soit X une v.a. continue à valeurs dans $\mathbb{R}$ de densité de probabilité f . La fonction de répartition de X notée F_X est définie par:

$$F_X(x) = \mathbb{P}(X \in]-\infty, x]) = \int_{-\infty}^x f(y) dy$$

Fonction de répartition

Fonction de répartition d'une v.a. discrète

Soit X une v.a. discrète à valeurs dans $X(\Omega)$. La fonction de répartition de X notée F_X est définie sur $\mathbb{R}$ par:

$$F_X(x) = \sum_{y \in X(\Omega) | y \leq x} \mathbb{P}(X = y)$$

Fonction de répartition d'une v.a. continue

Soit X une v.a. continue à valeurs dans $\mathbb{R}$ de densité de probabilité f . La fonction de répartition de X notée F_X est définie par:

$$F_X(x) = \mathbb{P}(X \in]-\infty, x]) = \int_{-\infty}^x f(y) dy$$

Dans le cas d'une v.a. continue, la fonction de répartition est continue et strictement croissante, ce qui en fait une bijection. En revanche, pour une v.a. discrète, cette fonction n'est pas continue.

Fonction inverse généralisée

Définition: Fonction inverse généralisée

Soit X une variable aléatoire de fonction de répartition F_X . On appelle inverse généralisée de F_X , ou fonction quantile de X , la fonction Q_X définie pour tout $u \in]0, 1[$ par

$$Q_X(u) = \inf \{x \in \mathbb{R} : F(x) \geq u\}.$$

Méthode d'inversion pour une variable aléatoire continue

Proposition: Simulation d'une v.a. continue

Soit X une v.a. continue de fonction de répartition F_X et U une v.a. suivant la loi uniforme $U([0, 1])$, alors la variable aléatoire:

$$Y = F_X^{-1}(U)$$

a la même loi de probabilité de X .

Méthode d'inversion pour une variable aléatoire continue

Proposition: Simulation d'une v.a. continue

Soit X une v.a. continue de fonction de répartition F_X et U une v.a. suivant la loi uniforme $U([0, 1])$, alors la variable aléatoire:

$$Y = F_X^{-1}(U)$$

a la même loi de probabilité de X .

Proposition

Soit X une v.a. continue de fonction de répartition F_X , alors la variable aléatoire:

$$U = F_X(X)$$

suit la loi uniforme $U([0, 1])$

Méthode d'inversion pour une variable aléatoire discrète

Proposition: Simulation d'une v.a. discrète

Soit X une v.a. discrète à valeurs dans $X(\Omega) = \{x_1, \dots, x_n\}$. Notons, pour $k = 1 : n$, $p_k = P(X = x_k)$.

Pour tout $u \in [0, 1]$, l'inverse généralisé est donné par:

$$Q_X(u) = \inf \left\{ x \in \mathbb{R} : \sum_{k=1}^n p_k \mathbf{1}_{\{x_k \leq x\}} \geq u \right\}$$

Alors, pour $U \sim U([0, 1])$, la variable aléatoire:

$$Y = \begin{cases} x_1 & \text{si } 0 \leq u \leq p_1 \\ x_2 & \text{si } p_1 < u \leq p_1 + p_2 \\ x_3 & \text{si } p_1 + p_2 < u \leq p_1 + p_2 + p_3 \\ \vdots & \\ x_n & \text{si } p_1 + \dots + p_{n-1} < u \leq 1 \end{cases}$$

suit la même loi que X .

Méthode de Box-Muller

La méthode d'inversion n'est pas utilisée pour la loi normale principalement parce que son inverse est très difficile à calculer, en raison de la complexité de la fonction de répartition de la loi normale.

Méthode de Box-Muller

La méthode d'inversion n'est pas utilisée pour la loi normale principalement parce que son inverse est très difficile à calculer, en raison de la complexité de la fonction de répartition de la loi normale.

Méthode de Box-Muller

La méthode de Box-Muller a été développée par George Box et Mervin Muller en 1958. Elle permet de générer une paire de variables aléatoires indépendantes qui suivent une loi normale standard, à partir de deux variables uniformes indépendantes.

Proposition

Soient R et Θ deux variables aléatoires indépendantes, telles que $R \sim \mathcal{E}(\frac{1}{2})$ et $\Theta \sim \mathcal{U}([0, 2\pi])$. Le couple aléatoire (Z_1, Z_2) défini par:

$$\begin{cases} Z_1 = \sqrt{R} \cos \Theta \\ Z_2 = \sqrt{R} \sin \Theta \end{cases}$$

est un gaussien standard.

Proposition

Soient R et Θ deux variables aléatoires indépendantes, telles que $R \sim \mathcal{E}(\frac{1}{2})$ et $\Theta \sim \mathcal{U}([0, 2\pi])$. Le couple aléatoire (Z_1, Z_2) défini par:

$$\begin{cases} Z_1 = \sqrt{R} \cos \Theta \\ Z_2 = \sqrt{R} \sin \Theta \end{cases}$$

est un gaussien standard.

Conséquence

Soit U et V deux variables aléatoires indépendantes et identiquement distribuées, suivant la loi $U([0, 1])$, alors les variables aléatoires définies par:

$$Z_1 = \sqrt{-2 \ln(U)} \cos(2\pi V) \text{ et } Z_2 = \sqrt{-2 \ln(U)} \sin(2\pi V)$$

sont indépendantes et suivent chacune une loi normale centrée réduite (standard).

Plan

Simulation de variables aléatoires

Loi uniforme

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $a \leq b \in \mathbb{R}$, alors la variable aléatoire:

$$X = a + (b - a) U$$

suit la loi $U([a, b])$.

Loi uniforme

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $a \leq b \in \mathbb{R}$, alors la variable aléatoire:

$$X = a + (b - a) U$$

suit la loi $U([a, b])$.

La transformation de U par la formule

$$X = a + (b - a) U$$

est une façon de "recaler" l'intervalle $[0, 1]$ pour l'étendre sur un intervalle plus large, ici $[a, b]$.

Loi exponentielle

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\lambda > 0$, alors la variable aléatoire:

$$X = \frac{-1}{\lambda} \ln(1 - U)$$

suit la loi exponentielle de paramètre λ .

Loi exponentielle

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\lambda > 0$, alors la variable aléatoire:

$$X = \frac{-1}{\lambda} \ln(1 - U)$$

suit la loi exponentielle de paramètre λ .

Remarque

La variable aléatoire $Y = \frac{-1}{\lambda} \ln(U)$ a la même loi de probabilité que X .

Loi de Cauchy

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\alpha \in \mathbb{R}, \beta > 0$, alors la variable aléatoire:

$$X = \alpha + \beta \tan\left(\pi\left(U - \frac{1}{2}\right)\right)$$

suit la loi de Cauchy de paramètres α, β .

Loi de Cauchy

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\alpha \in \mathbb{R}, \beta > 0$, alors la variable aléatoire:

$$X = \alpha + \beta \tan\left(\pi\left(U - \frac{1}{2}\right)\right)$$

suit la loi de Cauchy de paramètres α, β .

Remarque

Les variables aléatoires $Y = \alpha + \frac{\beta}{\tan(\pi u)}$ $Z = \alpha - \frac{\beta}{\tan(\pi u)}$ et ont la même loi de probabilité que X .

Loi de Weibull

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\lambda, k > 0$, alors la variable aléatoire:

$$X = \lambda (-\ln(1 - U))^{\frac{1}{k}} = \frac{\lambda}{\ln(1 - U)^{\frac{1}{k}}}$$

suit la loi de Weibull de paramètres λ, k .

Loi de Weibull

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\lambda, k > 0$, alors la variable aléatoire:

$$X = \lambda (-\ln(1 - U))^{\frac{1}{k}} = \frac{\lambda}{\ln(1 - U)^{\frac{1}{k}}}$$

suit la loi de Weibull de paramètres λ, k .

Remarque

La variable aléatoire $Y = \lambda (-\ln(U))^{\frac{1}{k}} = \frac{\lambda}{\ln(U)^{\frac{1}{k}}}$ a la même loi de probabilité que X .

Loi de Pareto

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\alpha, \beta > 0$, alors la variable aléatoire:

$$X = \beta (1 - U)^{\frac{-1}{\alpha}} = \frac{\beta}{(1 - U)^{\frac{1}{\alpha}}}$$

suit la loi de Pareto de paramètres β, α .

Loi de de Pareto

Proposition

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $\alpha, \beta > 0$, alors la variable aléatoire:

$$X = \beta (1 - U)^{\frac{-1}{\alpha}} = \frac{\beta}{(1 - U)^{\frac{1}{\alpha}}}$$

suit la loi de Pareto de paramètres β, α .

Remarque

La variable aléatoire $Y = \beta (U)^{\frac{-1}{\alpha}} = \frac{\beta}{U^{\frac{1}{\alpha}}}$ a la même loi de probabilité que X .

Loi de Bernoulli

Définition: Loi de Bernoulli

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $p \in]0, 1[$, alors la variable aléatoire:

$$X = \begin{cases} 0 & \text{Si } 0 < U \leq 1 - p \\ 1 & \text{Sinon} \end{cases}$$

suit la loi de Bernoulli de paramètre p .

Loi de Bernoulli

Définition: Loi de Bernoulli

Soit U une variable aléatoire suivant la loi uniforme $U([0, 1])$ et $p \in]0, 1[$, alors la variable aléatoire:

$$X = \begin{cases} 0 & \text{Si } 0 < U \leq 1 - p \\ 1 & \text{Sinon} \end{cases}$$

suit la loi de Bernoulli de paramètre p .

Remarque

La variable aléatoire $Y = 1 - 1 * (U \leq 1 - p)$ a la même loi de probabilité que X .

Loi binomiale

La simulation de la loi binomiale par la méthode d'inversion se base sur la proposition suivante:

Loi binomiale

La simulation de la loi binomiale par la méthode d'inversion se base sur la proposition suivante:

Lemme

Soit X une variable aléatoire. Alors, X suit la loi binomiale $B(n, p)$ si et seulement si, il existe n v.a. $X_1, \dots, X_n$ indépendantes de même loi de Bernoulli $B(p)$ tel que:

$$X = X_1 + \dots + X_n$$

Loi gaussienne

Pour la simulation de la loi normale (généralisée) de moyenne m et de variance σ^2 , on applique les résultats suivants.

Loi gaussienne

Pour la simulation de la loi normale (généralisée) de moyenne m et de variance σ^2 , on applique les résultats suivants.

Proposition

Soit X une variable aléatoire suivant la loi normale $\mathcal{N}(m, \sigma^2)$. Alors, on a:

$$X \stackrel{\mathcal{L}}{=} \sigma Z + m$$

avec Z suit la loi normale centrée réduite.

Loi gaussienne

Pour la simulation de la loi normale (généralisée) de moyenne m et de variance σ^2 , on applique les résultats suivants.

Proposition

Soit X une variable aléatoire suivant la loi normale $\mathcal{N}(m, \sigma^2)$. Alors, on a :

$$X \stackrel{\mathcal{L}}{=} \sigma Z + m$$

avec Z suit la loi normale centrée réduite.

Proposition

Soit U et V deux variables aléatoires indépendantes et identiquement distribuées, suivant la loi $U([0, 1])$, alors les variables aléatoires :

$$X = \sigma \sqrt{-2 \ln(U)} \cos(2\pi V) + m \text{ et } Y = \sigma \sqrt{-2 \ln(U)} \sin(2\pi V) + m$$

suivent la loi normale $\mathcal{N}(m, \sigma^2)$.

Plan

Vérification de la simulation

Approche graphique

ECDF (Empirical cumulative distribution function) offre une visualisation alternative de la distribution. Elle indique, pour un nombre donné, le pourcentage d'observations qui se situent en dessous un seuil.

Approche graphique

ECDF (Empirical cumulative distribution function) offre une visualisation alternative de la distribution. Elle indique, pour un nombre donné, le pourcentage d'observations qui se situent en dessous un seuil.

Définition

Soit X une variable aléatoire et $x = (x_1, \dots, x_n)$ n réalisation de X . Alors la fonction ECDF du vecteur x notée F_n est définie par l'expression suivante:

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{]-\infty, t]}(x_i), \quad \forall t \in \mathbb{R}$$

Approche graphique

ECDF (Empirical cumulative distribution function) offre une visualisation alternative de la distribution. Elle indique, pour un nombre donné, le pourcentage d'observations qui se situent en dessous un seuil.

Définition

Soit X une variable aléatoire et $x = (x_1, \dots, x_n)$ n réalisation de X . Alors la fonction ECDF du vecteur x notée F_n est définie par l'expression suivante:

$$F_n(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{]-\infty, t]}(x_i), \quad \forall t \in \mathbb{R}$$

Théorème (Kolmogorov-Smirnov)

$$\forall t \in \mathbb{R}, \lim_{n \rightarrow +\infty} F_n(t) = F_X(t)$$

La densité empirique est une estimation de la densité de probabilité d'une variable aléatoire continue.

La densité empirique est une estimation de la densité de probabilité d'une variable aléatoire continue.

Définition: Densité empirique

L'estimation par noyau (ou densité de Kernel) est une méthode non paramétrique permettant d'estimer la densité de probabilité d'une variable aléatoire. Elle constitue une approximation fluide et continue de la distribution des données.

La densité empirique est une estimation de la densité de probabilité d'une variable aléatoire continue.

Définition: Densité empirique

L'estimation par noyau (ou densité de Kernel) est une méthode non paramétrique permettant d'estimer la densité de probabilité d'une variable aléatoire. Elle constitue une approximation fluide et continue de la distribution des données.

La fonction de masse empirique est une estimation de la fonction de masse de probabilité d'une variable aléatoire discrète.

La densité empirique est une estimation de la densité de probabilité d'une variable aléatoire continue.

Définition: Densité empirique

L'estimation par noyau (ou densité de Kernel) est une méthode non paramétrique permettant d'estimer la densité de probabilité d'une variable aléatoire. Elle constitue une approximation fluide et continue de la distribution des données.

La fonction de masse empirique est une estimation de la fonction de masse de probabilité d'une variable aléatoire discrète.

Définition: Fonction de masse empirique

Soit X une variable aléatoire et $x = (x_1, \dots, x_n)$ n réalisation de X . Alors la fonction de masse empirique du vecteur x notée $\hat{P}_n$ est définie par l'expression suivante:

$$\hat{P}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{x=x_i}$$

Test de Kolmogorov-Smirnov

En statistiques, le test de Kolmogorov-Smirnov (KS) est un test d'hypothèse utilisé pour déterminer si un échantillon suit une loi donnée connue par sa fonction de répartition continue.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : La distribution empirique suit la distribution théorique spécifiée.
- H_1 : La distribution empirique ne suit pas la distribution théorique spécifiée.

Test de Kolmogorov-Smirnov

En statistiques, le test de Kolmogorov-Smirnov (KS) est un test d'hypothèse utilisé pour déterminer si un échantillon suit une loi donnée connue par sa fonction de répartition continue.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : La distribution empirique suit la distribution théorique spécifiée.
- H_1 : La distribution empirique ne suit pas la distribution théorique spécifiée.

Statistique

Soit $(X_1, X_2, \dots, X_n)$ un échantillon de taille n et on note $F_n(x)$ la fonction de répartition empirique et $F(x)$ la fonction de répartition théorique. La statistique KS est définie par :

$$D = \sup_x |F_n(x) - F(x)|$$

Test d'anderson Darling

Le test d'Anderson–Darling est un test d'hypothèse utilisé pour évaluer si un échantillon suit une loi de probabilité donnée, le plus souvent la loi normale. Il s'agit d'une amélioration du test de Kolmogorov–Smirnov, car il accorde plus de poids aux écarts dans les queues de la distribution.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : L'échantillon suit la distribution théorique spécifiée (par exemple, normale).
- H_1 : L'échantillon ne suit pas la distribution théorique spécifiée.

Test d'anderson Darling

Le test d'Anderson–Darling est un test d'hypothèse utilisé pour évaluer si un échantillon suit une loi de probabilité donnée, le plus souvent la loi normale. Il s'agit d'une amélioration du test de Kolmogorov–Smirnov, car il accorde plus de poids aux écarts dans les queues de la distribution.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : L'échantillon suit la distribution théorique spécifiée (par exemple, normale).
- H_1 : L'échantillon ne suit pas la distribution théorique spécifiée.

Statistique

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n \left[(2i-1) \ln F(X_{(i)}) + (2n+1-2i) \ln(1 - F(X_{(n+1-i)})) \right]$$

- $X_{(i)}$ sont les observations triées par ordre croissant,
- $F(X)$ est la fonction de répartition de la loi théorique,

Test de Shapiro-Wilk

Le test de Shapiro-Wilk permet de vérifier la normalité d'une variable. Il est applicable pour des échantillons allant jusqu'à 50 valeurs.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : Les données suivent une distribution normale.
- H_1 : Les données ne suivent pas une distribution normale.

Test de Shapiro-Wilk

Le test de Shapiro-Wilk permet de vérifier la normalité d'une variable. Il est applicable pour des échantillons allant jusqu'à 50 valeurs.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : Les données suivent une distribution normale.
- H_1 : Les données ne suivent pas une distribution normale.

Statistique

$$W = \frac{(\sum_{i=1}^n a_i X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

- X_i : observations triées par ordre croissant de taille n .
- $\bar{X}$: moyenne de l'échantillon (empirique).
- a_i : coefficients calculés à partir des espérances et de la matrice de covariance des valeurs ordonnées d'un échantillon normal standard.

Test du Khi-deux

Le test du χ^2 d'adéquation, ou test de conformité, permet de vérifier si un échantillon d'une variable aléatoire discrète X suit une loi de probabilité P définie a priori.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : Les données suivent la distribution théorique spécifique.
- H_1 : Les données ne suivent pas la distribution théorique spécifique.

Test du Khi-deux

Le test du χ^2 d'adéquation, ou test de conformité, permet de vérifier si un échantillon d'une variable aléatoire discrète X suit une loi de probabilité P définie a priori.

Hypothèses

Les hypothèses de ce test sont les suivantes:

- H_0 : Les données suivent la distribution théorique spécifique.
- H_1 : Les données ne suivent pas la distribution théorique spécifique.

Statistique

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

- O_i : nombre d'observations observées dans la i -ème classe.
- E_i : nombre d'observations attendues dans la i -ème classe sous H_0 .
- k : nombre de classes.